

Дескриптивная аналитика датасетов

Синтетические микроданные Бюро национальной статистики АСПР РК,
2021–2024

236

таблиц в восьми формах

72,6 млн

строк обработано полностью

4,68 ГБ →

300 МБ

CSV сведён в parquet

48 000 × 37

объединённая таблица

Команда «Котлы чудес»

Арнас Жаксаликов · Аружан Болат

Что в архиве

Восемь форм с разными единицами наблюдения: от предприятия до члена домохозяйства

Форма	Единица наблюдения	Строк	Файлов
1t_god	предприятие × показатель, год	30 025 899	4
1t_kv	то же, поквартально	24 480 242	16
d004	покупка или доход домохозяйства	8 612 484	192
2t	предприятие × показатель, оплата труда	7 328 814	4
t001	респондент обследования занятости	1 885 110	4
d008	член домохозяйства	169 059	4
d002	домохозяйство, субъективные оценки	95 542	8
d006	домохозяйство, жильё и благоустройство	46 743	4

01 Длинный формат

30 млн строк в форме 1-Т — это не 30 млн предприятий, а 52 289: одна строка равна одному значению одного показателя.

02 Конвейер из пяти шагов

parquet → рынок труда → мердж → анализ → графики. DuckDB считает потоково, достаточно 4 ГБ оперативной памяти.

Объединённая таблица домохозяйств

Четыре формы D-серии сходятся по ключу NOMER без потерь

d008	состав домохозяйства: размер, дети, пожилые, занятые, глава	12 000
d006	жильё: площадь, 42 удобства, 46 предметов длительного пользования	11 704
d004	деньги: доходы по 23 источникам, расходы по 7 блокам	11 948
d002	субъективные оценки условий жизни по шкалам	11 931

48 000 × 37

12 000 домохозяйств × 4 года

0

потерянных при соединении записей

37

признаков, включая производные

Производные признаки: доход и расходы на душу, норма сбережений, площадь на человека, индекс жилищной депривации, доля занятых, тип поселения. Глава домохозяйства определяется по RODSTVO = 1 — ровно одна строка на домохозяйство.

Заполненность и дрейф схемы

Разреженность анкет — норма, а вот смена схемы ломает код

Заполненность: анкеты с ветвлениями — на треть



Что меняется	2021	2024
Колонка со значением	GR1	VAL_NUM
Колонка региона	KATO	KATO1
Колонок в 1-Т годовой	16	30
Кодов ОКЭД	83	539
Регионов в выборке	17	20
Предприятий в 1-Т	70 874	52 289

Рост с 17 до 20 регионов — реформа 2022 года: Абай, Жетісу, Ұлытау. Падение числа предприятий — смена охвата выгрузки.

Отдельная ловушка: T-001 за 2022, строка 26332 — запятая внутри кавычек ломает автоопределение парсера

Аномалия генератора

Один регион искажает национальный показатель неформальной занятости вдвое



01 Что мы увидели


Алматинская область: 6,3 → 5,4 → 4,8 → **40,7%**. База ответов при этом стабильна, около 13 тысяч заполненных значений.

02 Что это значит

Без этого региона ряд по стране ровный: 3,2 / 3,3 / 2,9 / **3,0%**. Скачок — сбой генератора, а не экономика.

Восстановленный разрез: город и село

Поле К не описано в документации — три независимые формы дают согласованный ответ



- 01 Решающий признак**


Земельный участок: 85,3% против 20,2%. Такой разрыв не объясняется ничем, кроме типа поселения.
- 02 Подтверждение из третьей формы**

Работа без договора: 2,8% при К = 1 и 7,2% при К = 2. Сельская неформальность втрое выше городской.
- 03 Что это открывает**

Разрез город–село в данных есть, просто он не подписан. Направление кодировки стоит подтвердить у организаторов.

Динамика и возрастной профиль

Форма Т-001, около 470 тысяч респондентов в год



01 Занятость снижается монотонно
67,6 → 65,9% за четыре года, без единого года роста.


02 Гендерный разрыв не сокращается
Около 7 п.п. все четыре года, максимум в группе 25–34.

03 Возрастной профиль правдоподобен
Пик в 25–44, обрыв после 65: с 70,9% до 8,9%.

Средняя цифра прячет расхождение

Страна теряет 1,7 п.п. занятости, но разброс по регионам — 11,4 п.п.

Занятость: изменение 2021 → 2024



+6,3

п.п. в Астане — единственный
выраженный рост

-5,1

п.п. в ВКО, следом СКО с -3,6

01 Гипотеза для Результата 2

Если периферия теряет людей активного возраста и удерживает группу 65+, где занятость 8,9%, то национальное снижение демографическое, а не экономическое. Для политики это разные диагнозы.


02 Разрыв ряда

Абай, Жетісу и Ұлытау появились только в 2022 году, поэтому изменение к 2021 для них не считается.

Названия регионов сопоставлены по кодам КАТО и требуют сверки с официальным справочником

Бедность определяется числом иждивенцев

Самая устойчивая закономерность на всех 11 948 домохозяйствах 2024 года



в 2,4 раза

ниже доход на душу у многодетных, чем у одиночек

4,99 / 2,04

человек в домохозяйстве: нижний и верхний квинтиль



-16%

дохода на душу на каждого ребёнка, $R^2 = 0,375$

Удовлетворённость у многодетных при этом самая высокая: 7,71 против 7,29 — парадокс благополучия

Ограничение, которого нет в README

Блоки доходов и расходов откалиброваны независимо друг от друга



01 Проверка на продовольствие

Еда записана в вопросах 9–10 в натуральных единицах. Даже если засчитать все их поля как тенге, норма сбережений падает лишь до 56,9%.

02 Связи между признаками

Благоустройство ~ доход: **0,015**. Образование главы ~ доход: **0,014**. Работают только структурные признаки.

Что это значит для выбора темы


Гипотезы вида «обеспеченные живут в лучших условиях» на этих данных не проверяются. Работают темы про структуру домохозяйства и разрез город–село.

Результат 2, к 7 октября

Детская бедность как структурный эффект плюс сельская неформальность. Код, данные и все графики — в репозитории проекта.

До финала

Этапы конкурса от 21 сентября до 20 октября



Красным — что сделано, бирюзовым — следующий этап, серым — план.